非平稳测度下金融信息学习的基础极限：一个统一框架

春江量化研究

2026 年 4 月 26 日

摘要

本报告为金融市场中学习 Alpha 信号所需的最小样本复杂度建立了一个严格的界限。通过综合测度论随机分析、再生核希尔伯特空间（RKHS）中的率失真理论，以及神经正切核（NTK）的谱动态，我们推导出了一个普适极限。至关重要的是，我们引入了非平稳性系数 λ 来解释市场信息的时间衰减。我们提供了完整的数学推导，将 Girsanov 测度变换与模型的粉碎容量（shattering capacity）联系起来，为历史数据中的“信息破产”机制奠定了坚实的理论基础。

1. 市场信息的随机微积分表述

令 $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}_{t\geq 0}, \mathbb{P})$ 为带流概率空间。金融价格过程 S_t 并非在日历时间中运行，而是在受交易量从属的业务时间中运行。我们定义业务时间 τ_t 为绝对连续的随机时钟 $\tau_t = \int_0^t V_s ds$，其中 V_s 是交易量率。

在真实经验测度 $\mathbb{P}$ 下的资产收益率过程 $R_\tau = dS_\tau/S_\tau$，由潜在的 Alpha 信号 μ_τ 和标准布朗运动 W_τ 驱动：

$$dR_\tau = \mu_\tau d\tau + \sigma dW_\tau^{\mathbb{P}}. \tag{1}$$

定义 1. *市场数据集的香农信息密度 $\mathcal{I}_{data}$ 定义为经验测度 $\mathbb{P}$（存在信号）与风险中性等价鞅测度 $\mathbb{Q}$（纯噪声，$\mu_\tau = 0$）之间的期望对数似然比（Radon-Nikodym 导数）。*

引理 1 (基于 Girsanov 定理的信息密度)**.** *假设方向性 Alpha 信号幅度 μ_τ 与交易量强度 V_t 条件独立。给定信噪比（SNR）$\gamma^2 = \mathbb{E}[\mu^2]/\sigma^2$ 和交易量熵 $\mathcal{H}_v = \mathbb{E}[V]$，单位日历时间的期望信息密度为 $\mathcal{I}_{data} = \frac{1}{2}\gamma^2\mathcal{H}_v$。*

证明. 根据 Girsanov 定理，限制在 $\mathcal{F}_\tau$ 上的 Radon-Nikodym 导数由随机指数给出：

$$\left.\frac{d\mathbb{P}}{d\mathbb{Q}}\right|_{\mathcal{F}_\tau} = \exp\left(\int_0^\tau \frac{\mu_s}{\sigma^2} dR_s - \frac{1}{2}\int_0^\tau \frac{\mu_s^2}{\sigma^2} ds\right). \tag{2}$$

表示互信息的 Kullback-Leibler 散度为 $D_{KL}(\mathbb{P}\|\mathbb{Q}) = \mathbb{E}_{\mathbb{P}}\left[\log \frac{d\mathbb{P}}{d\mathbb{Q}}\right]$。代入 $dR_s = \mu_s ds + \sigma dW_s^{\mathbb{P}}$，Itô 积分在期望下消失（假设满足 Novikov 条件），得到：

$$D_{KL}(\mathbb{P}\|\mathbb{Q}) = \frac{1}{2}\mathbb{E}\left[\int_0^\tau \frac{\mu_s^2}{\sigma^2} ds\right]. \tag{3}$$

通过 $ds = V_t dt$ 映射回日历时间 t，积分变为 $\frac{1}{2}\mathbb{E}\left[\int_0^t \frac{\mu_s^2}{\sigma^2} V_s ds\right]$。基于 Alpha 幅度与交易量强度条件独立的结构性假设，期望可被分解，得出单位时间内的期望密度为 $\frac{1}{2}\gamma^2\mathbb{E}[V] = \frac{1}{2}\gamma^2\mathcal{H}_v$。 □

2. 测度非平稳性与时间衰减

在金融系统中，测度 $\mathbb{P}$ 是不断演化的。令 $\mathbb{P}_t$ 表示 t 时刻的测度。我们将 Alpha 信号相关性的退化建模为由连续漂移驱动的指数衰减。

定义 2. *非平稳性系数（Non-stationarity Coefficient）$\lambda > 0$ 刻画了有效信息随时间的指数衰减。对于在滞后期 s 观察到的数据，其有效密度为 $\mathcal{I}_{eff}(s) = \mathcal{I}_{data} \cdot e^{-\lambda s}$。*

3. RKHS 容量与 NTK 谱动态

考虑一个在经验风险景观上进行优化的深度神经网络 f_θ。随着网络宽度趋近于无穷大，f_θ 驻留在由神经正切核（NTK）$\Theta(x, x')$ 控制的再生核希尔伯特空间（RKHS）中。

引理 2 (模型信息需求)**.** *为了达到目标信息系数（IC）ρ，一个具有携带 Alpha 的有效维度 d_{eff}（即 RKHS 中信号相关子空间的迹）的模型，必须至少粉碎 $\mathcal{I}_{model} \approx \frac{1}{2} d_{eff} \rho^2$ 纳特（nats）的信息。*

证明. 根据针对高斯信道的香农率失真理论，对于现实中的 Alpha 信号（$\rho \ll 1$），互信息与相关性 ρ 的关系近似为 $I \approx \frac{1}{2}\rho^2$。将其扩展至由 d_{eff} 个携带信号的独立主成分张成的 RKHS，所需的总结构信息为 $\mathcal{I}_{model} = \frac{1}{2} d_{eff} \rho^2$。 □

引理 3 (NTK 谱偏差与 SGLD 信息瓶颈)**.** *假设神经网络通过随机梯度朗之万动力学（SGLD），在一个跨越连续回溯视野 T、包含 N 个样本的数据集上进行训练。假设 Alpha 信号驻留在 NTK 的次主导特征空间中，则有效吸收的总信息受到以下边界的限制：*

$$\mathcal{I}_{absorbed} \leq \frac{1}{\kappa} \frac{N}{2T} \gamma^2 \mathcal{H}_v \left(\frac{1 - e^{-\lambda T}}{\lambda} \right), \tag{4}$$

其中 $\kappa = \lambda_{max}(\Theta)/\lambda_{min}(\Theta)$ 是 NTK 谱在信号子空间上的条件数。

证明. 市场在视野 T 内提供的连续信息总量是衰减密度的积分。对于均匀分布在 T 内的 N 个离散样本的数据集，可用的总信息为：

$$I_{total} = N \cdot \frac{1}{T} \int_0^T \mathcal{I}_{eff}(s) ds = \frac{N \gamma^2 \mathcal{H}_v}{2T\lambda} (1 - e^{-\lambda T}).$$

根据 SGLD 平稳分布的 PAC-Bayesian 边界，从数据转移到模型参数的互信息 $I(f_\theta; \mathcal{D})$ 受到期望 Fisher 信息矩阵迹的限制，而在超参数化状态下，该矩阵收敛于 NTK 矩阵 Θ。由于神经网络的谱偏差（spectral bias），学习以正比于 Θ 的特征值 λ_i 的指数速率收敛。金融 Alpha 信号由于与主导市场 Beta 正交，主要占据低端谱（λ_{min}）。为了在不严重过拟合高特征值噪声分量的情况下均匀地实现所有 d_{eff} 维度的目标容量，有效信息转移遇到了瓶颈。可用信息被限制在一个分数范围内，其上限为谱比率 $\lambda_{min}/\lambda_{max} = \kappa^{-1}$。因此，$\mathcal{I}_{absorbed} \leq \kappa^{-1} I_{total}$，从而得出该界限。 □

4. 普适极限

我们现在将所需的容量（引理 2）与吸收的物理极限（引理 3）结合起来。

定理 1 (普适样本复杂度界限)**.** *为了在由衰减 λ 刻画的非平稳市场中，在连续回溯视野 T 内实现期望为 ρ 的 IC，所需的最小样本量 N_{min} 为：*

$$N_{min} = \left\lceil \frac{d_{eff} \cdot \kappa \cdot \rho^2 \cdot \lambda \cdot T}{\gamma^2 \cdot \mathcal{H}_v \cdot (1 - e^{-\lambda T})} \right\rceil. \tag{5}$$

证明. 根据信息守恒原理，成功的学习意味着 $\mathcal{I}_{model} \leq \mathcal{I}_{absorbed}$：

$$\frac{1}{2} d_{eff} \rho^2 \leq \frac{N}{2\kappa T} \gamma^2 \mathcal{H}_v \left(\frac{1 - e^{-\lambda T}}{\lambda} \right). \tag{6}$$

分离出 N 并针对离散样本应用向上取整函数，即可完成证明。需要注意的是，当 $\lambda \to 0$（平稳市场）时，$N_{min} \to \frac{d_{eff} \kappa \rho^2}{\gamma^2 \mathcal{H}_v}$，这反映了一个独立于 T 的恒定样本需求。 □

5. 结论与信息破产机制

衰减积分的引入意味着一个深刻的限制。令 $f_s = N/T$ 为数据采样频率。我们可以重写吸收的信息为：

$$\mathcal{I}_{absorbed} \leq \frac{f_s \gamma^2 \mathcal{H}_v}{2\kappa\lambda} (1 - e^{-\lambda T}). \tag{7}$$

随着回溯视野无限延伸（$T \to \infty$），项 $e^{-\lambda T} \to 0$。因此，从市场中可吸收的总信息达到了一个绝对的数学平台：

$$\lim_{T \to \infty} \mathcal{I}_{absorbed} = \frac{f_s \gamma^2 \mathcal{H}_v}{2\kappa\lambda}. \tag{8}$$

如果模型的目标复杂度所要求的信息超过了这个上限——具体而言，如果 $\frac{1}{2} d_{eff} \rho^2 > \frac{f_s \gamma^2 \mathcal{H}_v}{2\kappa\lambda}$——学习系统就进入了 *信息破产*（information bankruptcy）机制。在这种状态下，所需的 IC ρ 在物理上是无法实现的，这确凿地证明了仅仅 “增加更多的历史数据” 无法克服市场结构的根本衰减。

Algorithm 1: 最小样本复杂度估计

Input: 目标 IC ρ, 维度 d_{eff}, 条件数 κ, 信噪比 γ^2, 交易量熵 $\mathcal{H}_v$, 衰减率 λ, 视野 T
Output: 所需最小 K 线数量 N_{min}

```
numerator ⟵ d_eff · κ · ρ^2 · T
if λ ≤ 10^-8 then
    denominator ⟵ γ^2 · H_v · T
end
else
    numerator ⟵ numerator · λ
    decay_factor ⟵ 1.0 − exp(−λ · T)
    denominator ⟵ γ^2 · H_v · decay_factor
end
if denominator ≤ 0.0 then
    return Error: ” 无效的市场参数：信噪比或交易量为零”
end
N_min ⟵ ⌈numerator/denominator⌉
return N_min
```